

Factores influyentes en tipos de errores de concordancia para un corpus de cuatro aprendientes italianos de español L2 (material suplementario)

1. Selección de modelos

Se pueden usar las siguientes medidas para seleccionar modelos (Stroup, 2013; p. 193; Burnham & Anderson, 2010, caps. 2 y 4) [$\theta = \hat{\sigma}, \hat{\beta}$ es el vector de los coeficientes fijos y aleatorios estimados]:

(a) Schwarz: $BIC = -2L(\theta) + (p \times \log(s))$ [s = número de grupos; y $p = p_{\sigma} + (p_{\beta} = \text{rank}[X])$]; o sea el número de parámetros fijos más los aleatorios]. Menos es mejor.

(b) Akaike: $AIC = -2L(\theta) + 2p$. Menos es mejor.

(c) Akaike corregido: $AIC_c = -2L(\theta) + 2p(n^*/(n^* - p - 1))$ [$n^* = N$, tamaño muestral]; Corrige por muestra pequeña. Menos es mejor. Como heurística, se debería usar cuando¹: $\frac{n}{p} < 40$.

(d) Delta de Akaike: $\Delta AIC = \Delta = AIC_i - AIC_{min}$. Indican la distancia del modelo al mejor de todos (el de menor AIC). $\Delta_i \leq 2$ indica evidencia substancial para el modelo i .

(e) Pesos de Akaike (ω_i): indican el peso de la evidencia en favor de que modelo sea el mejor de entre todos los modelos candidatos. Es decir, responde a la pregunta: ¿Cómo soportan los datos al modelo i con respecto al resto de los modelos? Se define como:

$$\omega_{\text{modelo } i} = \frac{\exp(-\Delta_i/2)}{\sum_{i=1}^R \exp(-\Delta_i/2)}$$

donde $i = 1, \dots, R$ son los modelos considerados; y $\sum_{i=1}^R \omega_i = 1$.

(g) Ratio de evidencia (“Evidence Ratio”, [ER]): Ratio entre el peso de Akaike del modelo i -ésimo y el peso de Akaike del j -ésimo modelo: $\frac{W(i)}{W(j)}$. Muchas veces resulta de interés establecer i como el índice del mejor modelo: $\frac{W(1)}{W(j)}$. Los ER son invariantes a los demás modelos, a parte de i y j . Responden a la pregunta: ¿Cuántas más veces apoyan los datos al (mejor) modelo i respecto del modelo j ?

Una vez ordenados los modelos según alguno de los criterios, se puede reducir dicho conjunto por medio de un “conjunto de confianza” [*confidence set*] para el mejor modelo hallado. Burnham & Anderson (2010, p. 169) plantean tres alternativas: (i) sumar los pesos de Akaike

¹ Las medidas AIC y AIC_c convergen para n grande (manteniendo p constante). Es decir que cuando dicho ratio es suficientemente grande, tienden a seleccionar el mismo modelo. Entonces, en la práctica conviene usar siempre AIC_c .

de los modelos hasta alcanzar ≥ 0.95 (recuérdese que los pesos de Akaike suman 1); (ii) tomar los modelos tal que $\Delta_i \leq 2$, ya que indican evidencia sustancial para el modelo i ; (iii) establecer un corte usando ratios de evidencia (poniendo ahora el mejor modelo en el denominador), tal que²: $\frac{W(i)}{W(1)} > \frac{1}{8}$ ($\Delta_i = 2$). Los autores prefieren el tercer criterio debido a su invariancia por adición o borrado de modelos del conjunto de confianza.

Resulta imperativo tener en cuenta la incerteza debida al proceso de selección de modelos. De R modelos considerados se selecciona el mejor modelo i . Sin embargo, ¿Si hubieran cambiado los datos, se elegiría igualmente el modelo i como el mejor o habría variabilidad de entre las muestras de datos en cuanto al modelo elegido?. Una forma de tener en cuenta dicha incerteza es estimar la probabilidad de que un determinado predictor x_j esté en el mejor modelo si se pudiera recoger una nueva muestra de datos. Se trata de una medida de importancia relativa de los predictores. Se lleva a cabo sumando los pesos de Akaike de los modelos en los cuales el predictor x_j está presente: $W_+ = w_i I_j(g_i)$; donde $I_j(g_i)$ es la función indicadora que es “1” si x_j está en el modelo g_i o cero, si no. Entonces, la importancia relativa es la proporción de modelos en los cuales la predictora está presente.

Si se diera el caso de que, por ejemplo, $w(i) > 0.9$, entonces el modelo i es un claro ganador. En dicho caso es válido hacer inferencia mediante la estimación de los coeficientes β_i y sus errores típicos serán condicionales al modelo seleccionado. Si embargo, muchas veces, especialmente si el conjunto de modelos a considerar es grande, los modelos con $\Delta_i \leq 2$ poseen pesos de Akaike similares o bien deltas de Akaike cercanos al cero. En este caso, β_i puede diferir en los modelos del conjunto considerado. Una solución es usar la información de todos los modelos involucrados mediante un promedio pesado de los coeficientes. En este caso, los errores típicos de los coeficientes estimados no son condicionales al modelo (ganador) en cuestión sino a todo el conjunto de modelos. Por lo tanto, dichos errores típicos “incondicionales” tienen en cuenta la varianza que proviene del proceso de selección de modelos. Para promediar los coeficientes se utilizó:

$$\bar{\beta}_j = \sum_{i=1}^R w_i I_j(g_i) \hat{\beta}_{j,i} = W_+ \hat{\beta}_{j,+}$$

donde:

$$I_j(g_i) = \begin{cases} 1 & x_j \in g_i \\ 0 & x_j \notin g_i \end{cases}$$

y la suma es sobre todos los modelos del conjunto: $i = 1, \dots, R$. En este estimador se usan todos los modelos (“full average”), y cuando la predictora x_j no estuviera presente en un determinado modelo entonces $\beta_j = 0$. Tiene la ventaja de “correr hacia cero” [*Shrinkage*] las estimaciones de parámetros presentes en “modelos malos”. La varianza del estimador resulta:

² También podrían usarse: 0.135 ($\Delta_i = 4$); 0.082 ($\Delta_i = 5$); 0.05 ($\Delta_i = 6$)

$$\widehat{var}(\bar{\beta}_j) = \left[\sum_{i=1}^R w_i \sqrt{\widehat{var}(\bar{\beta}_j | g_i) + (\hat{\beta}_j - \bar{\beta}_j)^2} \right]^2$$

y su error típico: $\sqrt{\widehat{var}(\bar{\beta}_j)}$.

Se llevó a cabo selección de modelos (multinomiales generalizados) basado en medidas de información (Burnham & Anderson, 2010), optimizando la función de log-verosimilitud por medio de una red neuronal (utilizando el paquete *nnet* de *R* [Venables & Ripley (2002), p. 203]). Se decidió dividir el problema en dos grupos de variables, ya que utilizar todas las discretas implicaba una búsqueda exhaustiva aproximada de 4 millones de modelos. El primer grupo contenía en el modelo global a las variables predictoras: Fabs.SC.f, MORF.f, STEM.f, MOD, ES, ANIM, GRAMS, FAM.LEX.f, IMA.CONC.f, CUMRES.f, LDA. Mientras que el segundo contenía: POS, DIS, EST1, EST2, EST3, EST4, EST5, EST6, EST7, GRUPO6. Se usó *AIC* como medida de información para la selección. Se reporta la importancia relativa de las predictoras sobre 2048 modelos del grupo I (Cuadro 1), y 1024 del grupo II (Cuadro 2), sobre el total de modelos. Se observó que LDA, STEM.f, GRAMS, DIS, POS, EST4 poseían probabilidades debajo del 50 %. A continuación, se llevó a cabo el promedio de los coeficientes en el conjunto de “confianza” de los modelos (con la regla $\frac{w(i)}{w(1)} > \frac{1}{8}$). Las predictoras promediadas que resultaron significativas fueron: Fabs.SC.f, MOD, ANIM, FAM.LEX.f, ES, MORF.f, CUMRES.f, EST1, EST2, EST5, GRUPO6 (Cuadros 3 y 4).

Tabla 1. Importancia relativa de las predictoras: grupo 1

| | Names | x |
|----|------------|------|
| 1 | Fabs.SC.f | 1.00 |
| 2 | ANIM | 1.00 |
| 3 | MORF.f | 1.00 |
| 4 | CUMRES.f | 1.00 |
| 5 | FAM.LEX.f | 1.00 |
| 6 | MOD | 0.99 |
| 7 | ES | 0.90 |
| 8 | IMA.CONC.f | 0.72 |
| 9 | LDA | 0.44 |
| 10 | STEM.f | 0.22 |
| 11 | GRAMS | 0.11 |

Tabla 2. Importancia relativa de las predictoras: grupo 2

| | Names | X |
|----|--------|------|
| 1 | EST5 | 1.00 |
| 2 | EST1 | 0.98 |
| 3 | GRUPO6 | 0.96 |
| 4 | EST2 | 0.93 |
| 5 | EST6 | 0.82 |
| 6 | EST7 | 0.75 |
| 7 | EST3 | 0.62 |
| 8 | EST4 | 0.48 |
| 9 | DIS | 0.27 |
| 10 | POS | 0.06 |

Tabla 3. Promedio de los coeficientes con FULL AVERAGE ($p < 0.05$): grupo 1

| | Estimate | Std. Error | z value | Pr(> z) |
|----------------|----------|------------|---------|-----------|
| 1((Intercept)) | -3.799 | 0.691 | 5.494 | 0.000 |
| 1(Fabs.SC.f1) | -1.171 | 0.320 | 3.661 | 0.000 |
| 1(MOD2) | 0.646 | 0.309 | 2.089 | 0.037 |
| 2((Intercept)) | -3.543 | 0.924 | 3.835 | 0.000 |
| 2(ANIM1) | 1.833 | 0.431 | 4.248 | 0.000 |
| 2(FAM.LEX.f1) | -1.317 | 0.424 | 3.102 | 0.002 |
| 3((Intercept)) | -0.724 | 0.294 | 2.461 | 0.014 |
| 3(CUMRES.f2) | 0.470 | 0.173 | 2.711 | 0.007 |
| 3(ES2) | -18.804 | 8.832 | 2.129 | 0.033 |
| 3(FAM.LEX.f1) | -0.330 | 0.137 | 2.408 | 0.016 |
| 3(Fabs.SC.f1) | -0.402 | 0.168 | 2.395 | 0.017 |
| 3(MOD2) | 0.353 | 0.175 | 2.018 | 0.044 |
| 3(MOD3) | 0.482 | 0.199 | 2.425 | 0.015 |
| 3(MORF.f1) | -1.090 | 0.231 | 4.720 | 0.000 |
| 3(MORF.f2) | -0.691 | 0.304 | 2.272 | 0.023 |
| 4((Intercept)) | -3.841 | 0.598 | 6.420 | 0.000 |
| 4(CUMRES.f1) | 1.114 | 0.363 | 3.067 | 0.002 |

| | | | | |
|---------------|--------|-------|-------|-------|
| 4(CUMRES.f2) | 1.297 | 0.365 | 3.554 | 0.000 |
| 4(FAM.LEX.f1) | -0.464 | 0.230 | 2.019 | 0.043 |
| 4(MOD2) | 1.074 | 0.293 | 3.659 | 0.000 |

Tabla 4. Promedio de los coeficientes con FULL AVERAGE ($p < 0.05$): grupo 1

| | Estimate | Std. Error | z value | Pr(> z) |
|----------------|----------|------------|---------|-----------|
| 1((Intercept)) | -2.904 | 0.324 | 8.949 | 0.000 |
| 1(EST11) | -1.693 | 0.534 | 3.169 | 0.002 |
| 2((Intercept)) | -2.946 | 0.370 | 7.954 | 0.000 |
| 2(EST21) | -2.629 | 1.053 | 2.496 | 0.013 |
| 2(GRUPO66) | 1.419 | 0.546 | 2.600 | 0.009 |
| 3((Intercept)) | -1.845 | 0.176 | 10.506 | 0.000 |
| 3(GRUPO63) | 0.544 | 0.167 | 3.256 | 0.001 |
| 3(GRUPO65) | 0.974 | 0.300 | 3.245 | 0.001 |
| 4((Intercept)) | -2.914 | 0.316 | 9.226 | 0.000 |
| 4(EST51) | -0.971 | 0.460 | 2.111 | 0.035 |
| 4(GRUPO62) | 0.930 | 0.369 | 2.517 | 0.012 |

2. Modelo multinomial mixto bayesiano

Desde la perspectiva bayesiana los parámetros se consideran variables aleatorias y, como tales, llevan asociada una distribución, que a su vez, depende de un parámetro genérico ψ . Si se quiere hacer inferencia, la pregunta bayesiana sería: ¿cuáles son los valores del parámetro θ , que explican los datos Y (que están fijos)? Es decir que la respuesta es una *distribución* de dichos valores, que representa la incerteza en la estimación del parámetro θ . A esta distribución se la denomina “posterior” y se la denota: $p(\theta | y)$. Asigna diferente grado de probabilidad (“creencia”) a los posibles valores del parámetro θ *luego* de ver la evidencia. El problema de inferencia se resuelve mediante el teorema de *Bayes*, que reza:

$$p(\theta | y) = \frac{p(y | \theta)p(\theta | \psi)}{p(y)}$$

En donde: (i) $p(y | \theta)$ es la verosimilitud de los datos y (o sea, la distribución de y variando los valores del parámetro y dejando fijos los datos), que depende de parámetro genérico θ ; (ii) $p(\theta | \psi)$ es la distribución del parámetro θ , que depende del parámetro genérico ψ . $p(y)$ es la distribución marginal de los datos: $p(y) = \int_{\theta} p(y | \theta)p(\theta)d\theta$. Como ésta última no

depende de θ (porque al integrar sobre θ se obtiene una constante), se la considera como constante de normalización. La idea es asignar, *antes* de ver los datos, una distribución “prior” al parámetro θ , que indica una creencia sobre los posibles valores de θ . Esta creencia es actualizada por la distribución de θ teniendo en cuenta la evidencia (datos). En cualquier caso, la distribución posterior siempre es un compromiso entre verosimilitud de los datos y el *prior* del parámetro. La distribución posterior puede resumirse según: (i) la moda; (ii) la media; (iii) la mediana; (iv) el intervalo de *credibilidad* del 95 %. Este último da los valores de θ que dejan a la derecha y a la izquierda una densidad de probabilidad del 0.025. Es decir que indica la probabilidad de que el parámetro esté en un intervalo de credibilidad del 95 %.³.

La distribución posterior para el modelo mixto es (Sorensen & Gianola, (2002), cap.14.2):

$$p(\beta, u, \sigma_u^2 | y) = p(y | \beta, u)p(\beta)p(u | \sigma_u^2)p(\sigma_u^2 | \psi)$$

Las variables aleatorias se distribuyen como sigue ($c = 1,2,3,4$): (1) Respuesta: $y_{ijc} | \beta, u \sim \mathcal{M}(N; (\pi_1, \pi_2, \pi_3, \pi_4))$; (2) Coeficientes: $\beta_{kc} | \sigma_\beta^2 \sim \mathcal{N}(0, \sigma_\beta^2 = \sigma_e^2 + \pi^2/3)$; en notación vectorial: $\boldsymbol{\beta} | \sigma_\beta^2 \sim NMV(\mathbf{0}, \mathbf{B} \otimes \mathbf{V}_\beta)$, $\mathbf{B}=\mathbf{I}$; (3) Factores aleatorios: $u_j | \sigma_u^2 \sim \mathcal{N}(0, \sigma_u^2)$; donde: $\sigma_u^2 \sim \chi_u^2(1)$ [chi-cuadrada con 1 grado de libertad]; en notación vectorial: $\mathbf{u} | \sigma_u^2 \sim NMV(\mathbf{0}, \mathbf{A} \otimes \mathbf{V}_u)$; $\mathbf{A}=\mathbf{I}$; $V \sim W(v, S)$ [Wishart].

Las matrices de varianza-covarianza \mathbf{V}_u de los factores aleatorios son diagonales heterogéneas, con una varianza para cada efecto aleatorio. Los efectos aleatorios se consideran independientes. Por ejemplo, en el modelo más simple habrá cuatro efectos aleatorios de ordenada al origen, uno por cada categoría c , para *cada* grupo. Entonces la matriz tendrá en su diagonal las varianzas para cada uno de ellos. Es necesario estimar las distribuciones posteriores de los coeficientes (β), los factores aleatorios (u) y la varianza de los factores aleatorios (σ_u^2). La varianza de los errores no es un parámetro a estimar porque no es independiente de la media para los modelos (multi/bi)nomiales. Según recomendaciones de Hadfield (2010) se fijará la varianza de los errores en $V = \frac{1}{k}(I_{(k-1)} + J_{(k-1,k-1)})$, donde k es el número de categorías de la respuesta, I es la matriz identidad y J , una matriz de *unos*. Siguiendo a Gelman (2006) se usó el siguiente prior para β : $\beta_k \sim \mathcal{N}(0, \sigma_e^2 + \pi^2/3)$. Por otra parte, se tomará la sugerencia de Villemereuil et al. (2013) [ver también: Villemereuil (2012)] de utilizar *priors expandidos* para σ_u^2 , y usando una distribución χ^2 (que pertenece a la familia *gama*) con un grado de libertad⁴.

³ En cambio, en estadística frecuentista el intervalo de confianza indica que, si se repitiera muchas veces el experimento con diferentes muestras, el 95 % de la veces el verdadero parámetro poblacional caerá en el intervalo. Como no es una variable aleatoria (y por lo tanto carece de distribución) esto no es lo mismo que decir que hay una probabilidad del 95 % de que el parámetro caiga dentro del intervalo.

⁴ Se expande el efecto aleatorio u_i en dos componentes: $u_i = \alpha\eta_i$ con $\eta_i \sim \mathcal{N}(0; V_\eta)$; $\alpha \sim \mathcal{N}(0, V_\alpha)$; $V_\eta \sim W^{-1}(S, \nu)$ [Wishart inversa]. Implícitamente es lo mismo que definir $V_u = V_u/V_\alpha$, que se distribuye como una F de Fisher $\mathcal{F}(1, \nu)$. A medida que $\nu \rightarrow \infty$, dicha distribución se acerca a una $\chi_{(1)}^2$ (chi-cuadrado con un grado de libertad).

Generalmente estas varianzas se modelan como χ^2 inversas escaladas, pero la nueva distribución pone menos densidad de probabilidad cerca del cero, lo cual hace que la MCMC salga más fácilmente de la región del cero si se queda atascada.

La solución de la posterior $p(\beta, u, \sigma_u^2 | y)$ no es analítica explícita, sino que se hace por medios computacionales usando MCMC (Markov Chain Monte Carlo) y sus aplicaciones, como el muestreo de *Gibbs* (Blangiardo & Cameletti, 2015, cap. 4). El punto importante es que, satisfaciendo ciertas condiciones, la cadena llega (“converge”) a una distribución π de estados que es invariante (no se modifica con el tiempo). En el contexto bayesiano, la distribución invariante es precisamente $p(\theta | y)$, la posterior. La idea es tomar una secuencia de valores de los parámetros de la posterior $(\theta^1, \theta^2, \dots)$ hasta que la cadena alcance la distribución invariante; que será una aproximación a la posterior. La convergencia sucede luego de un (largo) número de interacciones, digamos $t > t_0$. Las interacciones hasta t_0 se descartan, y este conjunto de interacciones descartadas se conoce como periodo de *burn-in*. Sucede que en dicho periodo los valores muestreados pueden estar más correlacionados entre sí. En cambio los valores muestreados de la posterior (invariante) deben ser independientes. Por ello, un diagnóstico frecuente de convergencia de la cadena consiste en avaluar la autocorrelación r a diferentes *lags* o intervalos entre valores y verificar que $r < 0.1$. Cuanto más parámetros tenga el modelo, más se tardará en lograr la convergencia.

Por último, resulta conveniente presentar una medida bayesiana de comparación de modelos: el criterio de información de devianza [DIC] (Gelman et al., cap. 6). La devianza se define como menos dos veces el logaritmo de la verosimilitud del modelo: $D(y, \hat{\theta}) = -2 \log p(y | \hat{\theta})$, donde $\hat{\theta}$ es una estimación puntual, por ejemplo la moda o la media de la posterior del (vector de) parámetro(s). La esperanza $D_{avg}(y) = E(D(y, \theta) | y)$ puede estimarse como $D_{avg}(y) = \frac{1}{L} \sum_{k=1}^L D(y, \theta^{(l)})$, donde $\theta^{(l)}$ es la l -ésima muestra del parámetro, usando, por ejemplo, muestreo de Gibbs. Es decir que es un promedio de las devianzas calculadas sobre cada uno de los valores del parámetro obtenidos en la posterior. Usando estas dos fórmulas, se define el número efectivo de parámetros como: $p_D = \hat{D}_{avg}(y) - D(y, \hat{\theta})$. Entonces la medida DIC, que debe minimizarse para el mejor modelo, rezará: $DIC = 2\hat{D}_{avg}(y) - D(y, \hat{\theta}) = p_D + \hat{D}_{avg}(y) = D(y, \hat{\theta}) + 2p_D$.

3. Ajuste del modelo multinomial bayesiano

El modelo mixto multinomial bayesiano general para la concordancia i en el grupo j (el grupo está definido como *la sesión k anidada en el alumno g* [$k = 1, \dots, 12(14)$; $g = 1, \dots, 4$; $j = 1, \dots, 52$; $i = 1, \dots, 1857$], dado que la observación tiene la categoría $c = 1, \dots, 4$ se describe como sigue:

(1) Distribuciones y Priors: $y_{ij} = c | v_{0ij}, v_{1ij} \sim \text{multinomial}(N, (\pi_{ij1}\pi_{ij2}\pi_{ij3}\pi_{ij4}))$, $N = 1$; $\mathbf{v}_0 \sim \text{NMV}(\mathbf{0}, \mathbf{G}_0)$; $\mathbf{v}_1 \sim \text{NMV}(\mathbf{0}, \mathbf{G}_1)$; $\boldsymbol{\beta} \sim \text{NMV}(\mathbf{0}, \mathbf{V}_\beta)$;

(2) Matrices de varianza: $G_{INTERCEPT} = V \otimes A$; $G_{FAM.LEX.f} = V \otimes A$; $A = I$; $V=I$ (efectos aleatorios independientes).

$$V_{SESSION:ID,INTERCEPT} = \begin{bmatrix} \sigma_{v_01}^2 & & & \\ & \sigma_{v_02} & & \\ & & \sigma_{v_03} & \\ & & & \sigma_{v_04} \end{bmatrix} ; \quad V_{SESSION:ID;FAM:LEX} = \begin{bmatrix} \sigma_{v_1,FAM.LEX.f=0}^2 & \\ & \sigma_{v_1,FAM.LEX.f=1} \end{bmatrix}$$

(3) Función de enlace: $logit = g(E[y_{ij} = c | v_{0ij}, v_{1ij}]) = \log \left[\frac{\pi_{ijc}}{1 - \pi_{ijc}} \right];$

(4) Función inversa: $\pi_{ij} = g^{-1}(X\beta + Z_v v);$

(5) Predictor lineal: $\eta_{ij} = \varphi_{ij} + v_{0ij} + v_{1ij}$. Donde: φ_{ij} representa los efectos fijos; v_{0ij} y v_{1ij} son los efectos aleatorios “entre”.

(6) Tamaño muestral efectivo: $(Interactions - burn\ in)/thin = (4100000 - 100000)/2000 = 2000$.

(7) Modelo teórico: para $c = 1,2,3,4$, con $c = 0$ como categoría de referencia.

$$g(E[y_{ij} = c | v_{0ij}, v_{1ij}]) = \log \left[\frac{\pi_{ijc}}{1 - \pi_{ijc}} \right] = (\beta_{0c} + v_{0ic}) + (\beta_{1c} + v_{1ic})FAM.LEX.f \\ \beta_{2c}MOD_1 + \beta_{3c}MOD_2 + \beta_{4c}MOD_3 + \beta_{5c}CUMRES.f_1 + \beta_{6c}CUMRES.f_2 \\ \beta_{7c}Fabs.SC.f + \beta_{8c}MORF.f_1 + \beta_{9c}MORF.f_2 + \beta_{10c}EST1 + \beta_{11c}EST5 + \beta_{12c}EST2 \\ \beta_{13c}GRUPO6_2 + \beta_{14c}GRUPO6_3 + \beta_{15c}GRUPO6_4 + \beta_{16c}GRUPO6_5 + \beta_{17c}GRUPO6_6 \\ \beta_{18c}ES_1 + \beta_{19c}ES_2 + \beta_{20c}ANIM + \beta_{21c}TIME$$

La Tabla 6 describe los parámetros del modelo a estimar, para *cada* modelo $c = 1,2,3,4$. Hubo 22 efectos fijos a estimar por modelo. Considérense en primer lugar los diagnósticos de convergencia. En lo que respecta a las varianzas de los factores aleatorios, las correlaciones en $lags > 2000$ estaban debajo de $< 0.1^5$. Para el *lag 2000* (equivalente al *lag 1*) la autocorrelación fue mayor a 0.1 para $r_{intercept,c,lag=2000} = [1 = 0.33; 2 = 0.6; 3 = 0.21; 4 = 0.55]$; y < 0.1 para FAM.LEX.f. En suma, la autocorrelación fue moderada (*lag 1*) para las varianzas en las categorías 2 y 4. En cuanto a los coeficientes β , la correlación como mucho rondó 0.3. Por lo tanto, se considera que hubo una convergencia razonable de las

⁵ Como se muestrea de la posterior cada 2000 valores, las equivalencias serían: *lag 2000* = *lag 1*; *lag 10000* = *lag 5*, *lag 20000* = *lag 10*; *lag 100000* = *lag 50*.

distribuciones posteriores⁶. Además, las posteriores de las varianzas resultaron muy asimétricas a derecha. Por lo tanto se usó la moda como medida para la estimación puntual.

Tabla 5. Parámetros del modelo logístico multinomial bayesiano

| Parámetro | Descripción |
|---------------|--|
| v_{0ic} | la desviación del grupo i_c de la ordenada al origen |
| v_{1ic} | la desviación del grupo i_c de la media marginal de FAM.LEX.f. |
| β_{0c} | la media basal marginal |
| β_{1c} | el efecto de FAM.LEX.f, nivel 1 (referencia: FAM.LEX.f = 0) |
| β_{2c} | el efecto de MOD, nivel 1 (referencia: MOD = 0) |
| β_{3c} | el efecto de MOD, nivel 2 (referencia: MOD = 0) |
| β_{4c} | el efecto de MOD, nivel 3 (referencia: MOD = 0) |
| β_{5c} | el efecto de CUMRES.f, nivel 1 (referencia: CUMRES.f = 0) |
| β_{6c} | el efecto de CUMRES, nivel 2 (referencia: CUMRES.f = 0) |
| β_{7c} | el efecto de Fabs.SC.f, nivel 1 (referencia: Fabs.SC.f = 0) |
| β_{8c} | el efecto de MORF.f, nivel 1 (referencia: MORF.f = 0) |
| β_{9c} | el efecto de MORF.f nivel 2 (referencia: MOD = 0) |
| β_{10c} | el efecto de EST1, nivel 1 (referencia: EST1 = 0) |
| β_{11c} | el efecto de EST5, nivel 1 (referencia: EST1 = 0) |
| β_{12c} | el efecto de EST2, nivel 1 (referencia: EST1 = 0) |
| β_{13c} | el efecto de GRUPO6, nivel 2 (referencia: GRUPO6 = 1) |
| β_{14c} | el efecto de GRUPO6, nivel 3 (referencia: GRUPO6 = 1) |
| β_{15c} | el efecto de GRUPO6, nivel 4 (referencia: GRUPO6 = 1) |
| β_{16c} | el efecto de GRUPO6, nivel 5 (referencia: GRUPO6 = 1) |
| β_{17c} | el efecto de GRUPO6, nivel 6 (referencia: GRUPO6 = 1) |
| β_{18c} | el efecto de ES, nivel 1 (referencia: ES = 0) |
| β_{19c} | el efecto de ES, nivel 2 (referencia: ES = 0) |
| β_{20c} | el efecto de ANIM, nivel 1 (referencia: ES = 0) |
| β_{21c} | el efecto de TIME |

Las varianzas de los factores aleatorios son los que se detallan en las matrices:

⁶ El test de estacionariedad de Heidelberg y Welch (1981) propone como hipótesis nula que los valores muestreados de la posterior provienen de una distribución estacionaria. Ningún σ^2 de efectos aleatorios o β de efectos fijos rechazó dicha hipótesis nula.

$$V_{INTERCEPT} = \begin{bmatrix} 1.139 & & & \\ & 0.015 & & \\ & & 0.002 & \\ & & & 0.004 \end{bmatrix}; V_{FAM:LEX} = \begin{bmatrix} 0.001 & \\ & 0.562 \end{bmatrix};$$

Hubo $52 \times 4 = 208$ efectos aleatorios de ordenada al origen y $52 \times 2 = 104$ efectos aleatorios de FAM.LEX.f. Los desvíos típicos de los efectos aleatorios de ordenada al origen para cada categoría y para FAM.LEX.f resultaron:

$$\sigma_{0ic} = [c1 = 1.067; c2 = 0.125; c3 = 0.052; c4 = 0.068]$$

$$\sigma_{1ic} = [FAM.LEX.F(0) = 0.043; FAM.LEX.f(1) = 0.75]$$

Hubo más desvío en las categorías 1 y 2 respecto de las 3 y 4. El desvío de FAM.LEX.f(0) fue casi nulo. El coeficiente de ordenada al origen de *cada* categoría varió en términos del *logit* como $\beta_{0c} = [c1 = -2.28; c2 = -3.07; c3 = -0.72; c4 = -2.77]$ más / menos la desviación del efecto aleatorio “entre” de ordenada al origen de cada grupo. Análogamente, el efecto (coeficiente) de FAM.LEX.f varió en términos del *logit* en cada categoría como:

$\beta_{1c} = [c1 = -0.46; c2 = -1.36; c3 = -0.56; c4 = -0.89]$ más / menos la desviación del efecto “entre” de FAM.LEX.f de cada grupo.

En lo que atañe a los supuestos distribucionales de los factores aleatorios, se aplicó el test de *Shapiro-Wilks* para detectar desvíos groseros del supuesto de normalidad. Se tomó a la media como resumen de la posterior⁷. En cuanto a los efectos aleatorios de ordenada al origen, el supuesto no se cumplió para las categorías 1 y 2 ($p < 0.0001$) y se cumplió para las categorías 3 ($p = 0.77$) y 4 ($p = 0.45$). En los que atañe a los factores aleatorios de FAM.LEX.f se cumplió para ambos, aunque con menos evidencia para rechazar la hipótesis nula de normalidad para [FAM.LEX.f = 1] ($p = 0.054$), que para [FAM.LEX.f = 0] ($p = 0.39$). A continuación, el ajuste del modelo bayesiano total.

Tabla 6. Ajuste del modelo (todos los predictores)

| | mean | l.CI | u.CI | Eff | pMCMC | OR | l.CLOR | u.CLOR |
|---------------------|--------|--------|--------|----------|-------|-------|--------|--------|
| traitRES_CAT.1 | -2.281 | -3.443 | -1.081 | 2000.000 | 0.001 | 0.102 | 0.032 | 0.339 |
| traitRES_CAT.2 | -3.071 | -4.420 | -1.890 | 1572.478 | 0.001 | 0.046 | 0.012 | 0.151 |
| traitRES_CAT.3 | -0.724 | -1.432 | -0.085 | 2000.000 | 0.037 | 0.485 | 0.239 | 0.919 |
| traitRES_CAT.4 | -2.772 | -3.801 | -1.786 | 1594.264 | 0.001 | 0.063 | 0.022 | 0.168 |
| traitRES_CAT.1:TIME | -0.012 | -0.044 | 0.019 | 1332.941 | 0.458 | 0.988 | 0.957 | 1.020 |
| traitRES_CAT.2:TIME | -0.007 | -0.043 | 0.029 | 1093.957 | 0.734 | 0.993 | 0.958 | 1.029 |
| traitRES_CAT.3:TIME | 0.009 | -0.004 | 0.024 | 1870.334 | 0.184 | 1.009 | 0.996 | 1.024 |
| traitRES_CAT.4:TIME | 0.009 | -0.012 | 0.029 | 1874.825 | 0.384 | 1.009 | 0.989 | 1.030 |

⁷ La correlación de Pearson entre las estimaciones puntuales usando la media y la mediana estuvieron arriba de $r > 0.98$; con lo cual se consideró que las distribuciones eran simétricas. Por tanto, la media es un buen resumen de la distribución.

| | | | | | | | | |
|---------------------------|--------|--------|--------|----------|-------|-------|-------|-------|
| traitRES_CAT.1:MOD1 | -0.169 | -1.743 | 1.276 | 2000.000 | 0.847 | 0.845 | 0.175 | 3.582 |
| traitRES_CAT.2:MOD1 | -0.583 | -2.443 | 1.412 | 1713.370 | 0.569 | 0.558 | 0.087 | 4.104 |
| traitRES_CAT.3:MOD1 | -0.489 | -1.645 | 0.532 | 1687.632 | 0.382 | 0.613 | 0.193 | 1.702 |
| traitRES_CAT.4:MOD1 | -0.556 | -1.936 | 1.012 | 1609.775 | 0.475 | 0.574 | 0.144 | 2.750 |
| traitRES_CAT.1:MOD2 | 0.347 | -0.287 | 0.935 | 1812.128 | 0.293 | 1.415 | 0.751 | 2.546 |
| traitRES_CAT.2:MOD2 | 0.194 | -0.755 | 1.124 | 1276.952 | 0.644 | 1.215 | 0.470 | 3.077 |
| traitRES_CAT.3:MOD2 | 0.328 | -0.032 | 0.706 | 2038.619 | 0.089 | 1.388 | 0.968 | 2.025 |
| traitRES_CAT.4:MOD2 | 0.883 | 0.315 | 1.500 | 1596.517 | 0.001 | 2.419 | 1.370 | 4.480 |
| traitRES_CAT.1:MOD3 | -0.898 | -1.814 | -0.163 | 1173.143 | 0.032 | 0.407 | 0.163 | 0.850 |
| traitRES_CAT.2:MOD3 | -0.259 | -1.443 | 0.758 | 1208.766 | 0.683 | 0.772 | 0.236 | 2.135 |
| traitRES_CAT.3:MOD3 | 0.431 | 0.007 | 0.840 | 1738.849 | 0.045 | 1.538 | 1.007 | 2.316 |
| traitRES_CAT.4:MOD3 | 0.472 | -0.157 | 1.163 | 1655.423 | 0.149 | 1.603 | 0.855 | 3.201 |
| traitRES_CAT.1:Fabs.SC.fl | -1.277 | -2.036 | -0.491 | 1596.650 | 0.001 | 0.279 | 0.130 | 0.612 |
| traitRES_CAT.2:Fabs.SC.fl | 0.071 | -0.799 | 1.099 | 1278.310 | 0.900 | 1.073 | 0.450 | 3.002 |
| traitRES_CAT.3:Fabs.SC.fl | -0.424 | -0.799 | -0.012 | 1851.367 | 0.035 | 0.654 | 0.450 | 0.988 |
| traitRES_CAT.4:Fabs.SC.fl | -0.927 | -1.485 | -0.250 | 1530.948 | 0.003 | 0.396 | 0.226 | 0.778 |
| traitRES_CAT.1:ANIM1 | -0.121 | -0.772 | 0.543 | 1447.283 | 0.738 | 0.886 | 0.462 | 1.721 |
| traitRES_CAT.2:ANIM1 | 1.254 | 0.521 | 2.008 | 1190.987 | 0.003 | 3.503 | 1.684 | 7.445 |
| traitRES_CAT.3:ANIM1 | 0.132 | -0.192 | 0.467 | 1809.376 | 0.436 | 1.141 | 0.826 | 1.596 |
| traitRES_CAT.4:ANIM1 | 0.519 | -0.026 | 1.031 | 1673.390 | 0.063 | 1.680 | 0.974 | 2.803 |
| traitRES_CAT.1:ES1 | 0.541 | -0.647 | 1.677 | 1797.495 | 0.382 | 1.718 | 0.524 | 5.351 |
| traitRES_CAT.2:ES1 | 0.066 | -1.274 | 1.383 | 1680.962 | 0.933 | 1.068 | 0.280 | 3.989 |
| traitRES_CAT.3:ES1 | -0.308 | -1.049 | 0.379 | 2000.000 | 0.426 | 0.735 | 0.350 | 1.461 |
| traitRES_CAT.4:ES1 | 0.482 | -0.519 | 1.454 | 1799.522 | 0.355 | 1.620 | 0.595 | 4.281 |
| traitRES_CAT.1:ES2 | -0.672 | -2.717 | 1.237 | 1867.843 | 0.525 | 0.511 | 0.066 | 3.445 |
| traitRES_CAT.2:ES2 | 0.111 | -1.610 | 1.923 | 1505.873 | 0.872 | 1.117 | 0.200 | 6.842 |
| traitRES_CAT.3:ES2 | -2.007 | -3.532 | -0.624 | 1601.730 | 0.004 | 0.134 | 0.029 | 0.536 |
| traitRES_CAT.4:ES2 | 0.046 | -1.304 | 1.484 | 1548.543 | 0.952 | 1.047 | 0.272 | 4.409 |
| traitRES_CAT.1:MORF.fl | -0.191 | -1.150 | 0.779 | 2000.000 | 0.667 | 0.826 | 0.317 | 2.178 |
| traitRES_CAT.2:MORF.fl | -0.962 | -2.058 | 0.274 | 1537.687 | 0.100 | 0.382 | 0.128 | 1.315 |
| traitRES_CAT.3:MORF.fl | -1.233 | -1.714 | -0.746 | 2000.000 | 0.001 | 0.291 | 0.180 | 0.474 |
| traitRES_CAT.4:MORF.fl | -0.630 | -1.342 | 0.097 | 1733.746 | 0.091 | 0.533 | 0.261 | 1.102 |
| traitRES_CAT.1:MORF.f2 | -0.342 | -1.359 | 0.757 | 1867.880 | 0.540 | 0.710 | 0.257 | 2.132 |
| traitRES_CAT.2:MORF.f2 | -0.086 | -1.293 | 1.039 | 1725.062 | 0.870 | 0.917 | 0.274 | 2.826 |
| traitRES_CAT.3:MORF.f2 | -0.949 | -1.557 | -0.287 | 1647.699 | 0.005 | 0.387 | 0.211 | 0.751 |
| traitRES_CAT.4:MORF.f2 | -0.497 | -1.299 | 0.374 | 1724.647 | 0.264 | 0.608 | 0.273 | 1.454 |
| traitRES_CAT.1:FAM.LEX.fl | -0.464 | -1.105 | 0.173 | 1544.699 | 0.163 | 0.629 | 0.331 | 1.189 |
| traitRES_CAT.2:FAM.LEX.fl | -1.362 | -2.201 | -0.475 | 1098.049 | 0.001 | 0.256 | 0.111 | 0.622 |
| traitRES_CAT.3:FAM.LEX.fl | -0.563 | -0.953 | -0.141 | 2000.000 | 0.004 | 0.570 | 0.386 | 0.868 |
| traitRES_CAT.4:FAM.LEX.fl | -0.897 | -1.432 | -0.360 | 1533.184 | 0.001 | 0.408 | 0.239 | 0.698 |
| traitRES_CAT.1:CUMRES.fl | 0.137 | -0.573 | 0.862 | 1863.065 | 0.736 | 1.147 | 0.564 | 2.369 |
| traitRES_CAT.2:CUMRES.fl | 0.404 | -0.443 | 1.269 | 1052.338 | 0.351 | 1.498 | 0.642 | 3.558 |
| traitRES_CAT.3:CUMRES.fl | -0.038 | -0.449 | 0.373 | 2000.000 | 0.855 | 0.962 | 0.638 | 1.452 |
| traitRES_CAT.4:CUMRES.fl | 0.704 | 0.025 | 1.322 | 1653.229 | 0.026 | 2.021 | 1.026 | 3.749 |
| traitRES_CAT.1:CUMRES.f2 | 0.046 | -1.058 | 1.130 | 2000.000 | 0.951 | 1.047 | 0.347 | 3.097 |
| traitRES_CAT.2:CUMRES.f2 | -0.510 | -1.849 | 0.874 | 1403.991 | 0.468 | 0.601 | 0.157 | 2.396 |
| traitRES_CAT.3:CUMRES.f2 | -0.222 | -0.834 | 0.433 | 2000.000 | 0.467 | 0.801 | 0.434 | 1.542 |
| traitRES_CAT.4:CUMRES.f2 | 0.503 | -0.379 | 1.401 | 1616.208 | 0.296 | 1.653 | 0.685 | 4.060 |
| traitRES_CAT.1:EST11 | -1.773 | -2.720 | -0.924 | 914.828 | 0.001 | 0.170 | 0.066 | 0.397 |
| traitRES_CAT.2:EST11 | -0.444 | -1.288 | 0.497 | 1306.433 | 0.347 | 0.641 | 0.276 | 1.644 |

| | | | | | | | | |
|------------------------|--------|--------|--------|----------|-------|-------|-------|-------|
| traitRES_CAT.3:EST11 | -0.077 | -0.476 | 0.314 | 2000.000 | 0.691 | 0.926 | 0.621 | 1.368 |
| traitRES_CAT.4:EST11 | -0.893 | -1.539 | -0.229 | 1130.814 | 0.008 | 0.410 | 0.215 | 0.796 |
| traitRES_CAT.1:EST21 | 0.118 | -0.641 | 0.818 | 1760.448 | 0.755 | 1.125 | 0.527 | 2.267 |
| traitRES_CAT.2:EST21 | -1.510 | -2.773 | -0.198 | 672.114 | 0.021 | 0.221 | 0.062 | 0.820 |
| traitRES_CAT.3:EST21 | 0.272 | -0.124 | 0.672 | 2000.000 | 0.205 | 1.313 | 0.884 | 1.959 |
| traitRES_CAT.4:EST21 | 0.102 | -0.481 | 0.722 | 1711.588 | 0.740 | 1.107 | 0.618 | 2.058 |
| traitRES_CAT.1:EST51 | -0.865 | -2.059 | 0.175 | 1556.623 | 0.120 | 0.421 | 0.128 | 1.191 |
| traitRES_CAT.2:EST51 | -2.139 | -3.540 | -0.729 | 856.514 | 0.001 | 0.118 | 0.029 | 0.483 |
| traitRES_CAT.3:EST51 | -0.107 | -0.715 | 0.427 | 2000.000 | 0.730 | 0.899 | 0.489 | 1.533 |
| traitRES_CAT.4:EST51 | -1.855 | -2.756 | -1.088 | 1372.963 | 0.001 | 0.156 | 0.064 | 0.337 |
| traitRES_CAT.1:GRUPO62 | -0.603 | -1.757 | 0.401 | 1510.496 | 0.275 | 0.547 | 0.173 | 1.493 |
| traitRES_CAT.2:GRUPO62 | -0.520 | -1.809 | 0.640 | 1549.728 | 0.396 | 0.594 | 0.164 | 1.897 |
| traitRES_CAT.3:GRUPO62 | 0.170 | -0.412 | 0.781 | 2000.000 | 0.565 | 1.186 | 0.663 | 2.183 |
| traitRES_CAT.4:GRUPO62 | 0.664 | -0.083 | 1.472 | 1576.769 | 0.100 | 1.943 | 0.920 | 4.357 |
| traitRES_CAT.1:GRUPO63 | -0.139 | -0.987 | 0.661 | 1723.035 | 0.756 | 0.871 | 0.373 | 1.937 |
| traitRES_CAT.2:GRUPO63 | -0.504 | -1.695 | 0.654 | 1029.938 | 0.405 | 0.604 | 0.184 | 1.923 |
| traitRES_CAT.3:GRUPO63 | 0.074 | -0.342 | 0.488 | 1647.641 | 0.747 | 1.077 | 0.711 | 1.629 |
| traitRES_CAT.4:GRUPO63 | -0.488 | -1.150 | 0.204 | 1587.010 | 0.163 | 0.614 | 0.317 | 1.226 |
| traitRES_CAT.1:GRUPO64 | -0.218 | -1.119 | 0.687 | 1710.223 | 0.661 | 0.804 | 0.327 | 1.987 |
| traitRES_CAT.2:GRUPO64 | -0.278 | -1.364 | 0.945 | 1299.757 | 0.659 | 0.757 | 0.256 | 2.573 |
| traitRES_CAT.3:GRUPO64 | -0.008 | -0.448 | 0.499 | 1813.817 | 0.970 | 0.992 | 0.639 | 1.647 |
| traitRES_CAT.4:GRUPO64 | -0.067 | -0.854 | 0.638 | 1650.738 | 0.864 | 0.935 | 0.426 | 1.893 |
| traitRES_CAT.1:GRUPO65 | -0.586 | -2.041 | 0.842 | 1737.677 | 0.435 | 0.557 | 0.130 | 2.321 |
| traitRES_CAT.2:GRUPO65 | -0.591 | -2.236 | 0.893 | 1723.644 | 0.466 | 0.554 | 0.107 | 2.443 |
| traitRES_CAT.3:GRUPO65 | 0.519 | -0.169 | 1.146 | 2000.000 | 0.117 | 1.681 | 0.845 | 3.145 |
| traitRES_CAT.4:GRUPO65 | -1.207 | -2.366 | 0.050 | 1367.219 | 0.036 | 0.299 | 0.094 | 1.051 |
| traitRES_CAT.1:GRUPO66 | -0.242 | -1.545 | 1.177 | 1369.080 | 0.763 | 0.785 | 0.213 | 3.246 |
| traitRES_CAT.2:GRUPO66 | 0.752 | -0.351 | 2.051 | 1864.481 | 0.237 | 2.121 | 0.704 | 7.777 |
| traitRES_CAT.3:GRUPO66 | -0.251 | -1.139 | 0.675 | 2000.000 | 0.605 | 0.778 | 0.320 | 1.964 |
| traitRES_CAT.4:GRUPO66 | 0.138 | -0.959 | 1.388 | 1836.897 | 0.797 | 1.148 | 0.383 | 4.005 |

mean = media de la posterior, l CI = Int. de credibilidad del 95 por ciento, extremo inferior, u CI = Int. de credibilidad del 95 por ciento, extremo superior; eff = tamaño muestral efectivo; pMCMC = p valor; OR = exp(mean), l CI OR = exp(l CI), u CI OR = exp(u CI).

4. Código de R

Con el objetivo de fomentar la replicación de los resultados de este trabajo, se brinda en adjunto el script de R usado para el análisis, junto a las bases de datos.

Referencias

Blangiardo, M. y Cameletti, M. (2016). *Spatial and Spatio-Temporal Bayesian Models with R-INLA*. John Wiley and Sons.

Burnham, K. P., & Anderson, D. R. (2010). *Model selection and multimodel inference: a practical information-theoretic approach*. Springer.

Gelman, A. (2006). Prior distributions for variance parameters in hierarchical models. *Bayesian Analysis*, 1(3), 515–533.

Gelman, A., Carlin, J., Stern, H. S. y Rubin, D. (2004). *Bayesian Data Analysis*. Chapman y Hall/CRC.

Hadfield, J. (2010). MCMCglmm: Markov chain monte carlo methods for generalised linear mixed models. Recuperado de <http://cran.r-project.org/web/packages/MCMCglmm/index.html>.

Heidelberger, P. y Welch, P. D. (1981). A spectral method for confidence interval generation and run length control in simulations. *Communications of the ACM*, 24(4), 233-245.

Sorensen, D. y Gianola, D. (2002). *Likelihood, bayesian and MCMC methods in quantitative genetics*. Springer.

Stroup, W. W. (2013). *Generalized Linear Mixed Models: Modern Concepts, Methods and Applications*. CRC Press, Chapman Hall.

Villemereuil, P. (2012). Estimation of a biological trait heritability using the animal model: how to use the mcmcglmm r package. Recuperado de <http://devillemereuil.legitux.org/downloads/>

Villemereuil, P., Gimenez, O. y Doligez, B. (2013). Comparing parent-offspring regression with frequentist and bayesian animal models to estimate heritability in wild populations: a simulation study for gaussian and binary traits. *Methods in Ecology and Evolution*, 4, 260–275.